

SolarScanner: Olağanüstü Durumlarda Uydu Görüntüleri ile Kentsel Hasar Tespiti için Derin Öğrenme Tabanlı Bütünleşik Yaklaşım

Tuğcan Topaloğlu
Yıldız Teknik Üniversitesi

İstanbul, Türkiye
tugcan.topaloglu@std.yildiz.edu.tr

Özetçe—Bu çalışma yaygın olarak görülebilen deprem, sel, kasırga veya çatışma gibi olağanüstü durumlarda şehirlerde meydana gelen hasarı hızlı ve otomatik bir şekilde tespit edilmesini amaçlayan SolarScanner (veya solars) adlı iki aşamalı bir derin öğrenme mimarisini sunmaktadır. Afet ve savaş sonrası müdahale ve planlama süreçlerinde kritik öneme sahip olan hasar tespiti geleneksel yöntemler ile yapıldığında yavaş, maliyetli ve tehlikeli olabilmektedir. Bu faktörler de hızlı reaksiyon verme imkânını azaltmaktadır. Önerilen sistem ise bu zorlukları aşmak için yüksek çözünürlüklü, çok katmanlı uydu ve hava görüntülerini kullanarak binaların konumlarını, kapladığı alanları yüksek doğrulukla çıkarmaktadır. Belirtilen tümleşik model için ilk aşama SpaceNet veri seti ile yüksek çözünürlüklü 300 binden fazla uydu görüntüsü ve yaklaşık 67 bin km² alan U-Net mimarisine ve ResNet-50 yapısıyla segmentasyon modeli olarak eğitilmiştir. Bu modelin eğitiminde ortaya çıkan uydu görüntülerindeki ciddi sınıf dengesizliği problemi, Focal Loss ve Dice Loss fonksiyonlarının birleşimiyle etkin bir şekilde çözülmüştür. İkinci aşamada ise tespit edilen her bir bina orijinal görüntüden alınarak xBD veri seti ile eğitilmiş Vision Transformer (ViT) tabanlı sınıflandırma modeline aktarılmaktadır. Bu model her binanın hasarını hasarsız, az hasarlı, ağır hasarlı veya yıkılmış olmak üzere dört sınıfta kategorize etmektedir. Deneyisel sonuçlar segmentasyon modelinin eğitim veri setinde 0.76'nın üzerinde bir IoU (Intersection over union) skoruna ve hasar tespit modelinin ise doğrulama ve test üzerinde %98 oranında başarılı olduğunu göstermiştir. Bu bütünleşik yaklaşım, afet müdahale ekiplerine hızlı, geniş ölçekli ve objektif bir hasar analizi sunarak kaynakların daha etkin planlanmasına olanak tanıma potansiyeli taşımaktadır. Aktif savaşlarda ve afetlerde kullanılabilecek yenilikçi bir model oluşturulmuştur.

Anahtar Kelimeler—uydu görüntüleri, bina segmentasyonu, hasar değerlendirme, Vision Transformer, SegFormer, afet yönetimi, ResNet, hasar tespiti, derin öğrenme, U-Net, uzaktan algılama.

I. GİRİŞ

Doğal afetler, savaşlar, meskul mahal çatışmalar ve insan kaynaklı krizler, 21. yüzyılın en önemli sorunları arasında yer almaktadır. Dünya genelinde her yıl binlerce insanın hayatını kaybetmesine, milyonlarca insanın yerinden edilmesine ve milyarlarca dolarlık ekonomik zarara yol açan bu olaylar, toplumların sosyo-ekonomik dokusunu bozmaktadır. [1] Depremler, kasırgalar, seller ve askeri çatışmalar gibi olağanüstü durumların hemen ardından, etkilenen bölgelerdeki hasarın boyutunun hızlı ve doğru bir şekilde belirlenmesi, müdahale sürecinin etkinliği açısından hayati bir rol oynamaktadır. Bu ilk değerlendirme, arama-kurtarma çalışmalarının hangi bölgelerde yoğunlaştırılacağını, acil durum barınaklarının nereye

kurulacağını, kritik altyapı onarımlarının önceliklendirilmesini ve insani yardım kaynaklarının nasıl dağıtılacağını belirlemede temel bir kaynak sağlar.

Özellikle Türkiye ve çevresinde bulunan doğal afet ve çatışma yoğunluğu bir çok örnekle görülebilmektedir. 2023 Kahramanmaraş, 2011 Van, 2003 Bingöl, 1999 Kocaeli, 1998 Adana gibi ve daha fazlası bir çok büyük felaket Türkiye'nin jeopolitik konumu dolayısıyla felaket durumlarındaki tespiti önemli hale getirmektedir.

Geleneksel hasar tespit yöntemleri, genellikle saha ekiplerinin fiziksel olarak binaları ve altyapıyı incelemesine dayanır. Bu süreç, geniş alanlarda yavaş ve iş gücü yoğun olmasının yanı sıra, artçı sarsıntılar, sel sularının çekilmemesi veya devam eden çatışmalar gibi tehlikeler dolayısıyla müdahale ekipleri için de büyük riskler taşımaktadır. Bu yöntemlerin yavaşlığı, kritik saatler olarak bilinen ilk 72 saat içinde hayat kurtarma potansiyelini önemli ölçüde azaltmaktadır. [2]

Son yıllarda, uzaktan algılama teknolojilerindeki gelişmeler, özellikle yüksek çözünürlüklü optik uydu görüntülerinin, sentetik aralıklı radar (SAR) verilerinin ve insansız hava aracı (İHA) görüntülerinin yaygınlaşması, afet yönetimi alanında yeni bir çığır açmıştır. Bu teknolojiler, geniş coğrafi alanların anlık durumunu güvenli bir mesafeden, hızlı ve tekrarlanabilir bir şekilde elde etme imkânı sunmaktadır. Ancak, bu büyük hacimli görsel verinin manuel olarak analizi, yine zaman alıcı, öznel ve ölçeklenmesi zor bir süreçtir. İşte bu noktada, bilgisayarlı görü ve derin öğrenme alanındaki atılımlar, bu süreci otomatize etmek için güçlü ve devrim niteliğinde araçlar sunmaktadır.

Bu çalışmanın temel motivasyonu, uzaktan algılama verilerini kullanarak kentsel alanlardaki yapısal hasarı otonom bir şekilde tespit edebilen, hızlı, doğru ve ölçeklenebilir bir sistem geliştirmektir. "SolarScanner" olarak adlandırdığımız bu proje, bu karmaşık problemi iki temel ve yönetilebilir alt probleme ayıran bütünleşik bir ardışık düzen (pipeline) önermektedir: (1) Bir görüntüdeki binaların yerlerini ve sınırlarını doğru bir şekilde bulmak (bina segmentasyonu), ve (2) tespit edilen her bir binanın hasar durumunu sınıflandırmak (hasar tespiti). Amaç bu işlemlerin canlı uydu görüntülerinden ve/veya drone sürülerinden yapılabilmesidir. Anlık olarak yukarıdan gözükebilecek en muhtemel görüntü ile hızlıca aksiyon alınabilmesini sağlamaktır.

Yöntemimizin getirdiği iki aşamalı yaklaşım, problemin

doğasına uygun bir çözüm stratejisi sunar. İlk aşama olan bina tespiti, semantik segmentasyon görevi olarak ele alınmıştır. Bu görev için, medikal görüntülemeye uzakta algılamaya kadar birçok alanda başarısı kanıtlanmış olan U-Net mimarisi ve özellik çıkarıcı (feature-extraction) olarak ImageNet üzerinde önceden eğitilmiş güçlü bir ResNet-50 kodlayıcısı kullanılmıştır. Bu model, farklı kentsel dokulara sahip uydu görüntüleri içeren SpaceNet veri seti kullanılarak eğitilmiştir. Bu aşamadaki en büyük teknik zorluk, uydu görüntülerinde bina piksellerinin toplam pikseller içindeki oranının çok düşük olması nedeniyle ortaya çıkan ciddi sınıf dengesizliği problemidir. Bu zorluğun üstesinden gelmek için, Focal Loss ve Dice Loss fonksiyonlarını birleştiren hibrit bir kayıp fonksiyonu tasarlanmış ve uygulanmıştır.

İkinci aşama olan hasar sınıflandırması için, son yıllarda bilgisayarlı görü alanında büyük bir başarı yakalayan ve küresel bağlamı anlama yeteneğiyle öne çıkan Vision Transformer (ViT) mimarisi tercih edilmiştir. Bu nedeni ise güncel bir transformer mimarisi olan ViT'in parçalama yöntemi (patch) ile oldukça yüksek başarı elde edebilmesidir. ViT'nin, bir binadaki hasarı (örneğin, yapısal deformasyon, çatlaklar, enkaz yığınları, çatı çökmesi, bombalanarak yıkılması) değerlendirmek için gerekli olan hem yerel bilgiyi hem de bütünsel yapısal bilgiyi etkin bir şekilde yakalaması beklenmektedir. Bu model, ilk aşamada tespit edilen binaların orijinal görüntüden kırılmasıyla elde edilen "bina parçacıkları (patch)" ve bu parçacıkların hasar seviyelerini içeren, alanındaki en kapsamlı veri setlerinden biri olan xView2 (xBD) ile eğitilmiştir.

Bu makalede, önerilen SolarScanner (solars) sisteminin mimari tasarımı, kullanılan veri setleri, karşılaşılan zorluklar ve uygulanan veri ön işleme adımları, modellerin eğitim süreçleri ve hiperparametre ayarları detaylı bir şekilde açıklanmaktadır. Elde edilen deneysel sonuçlar, hem segmentasyon hem de sınıflandırma modellerinin performansını nicel metrikler (IoU, Accuracy, F1-Score) ve nitel analizler (görsel çıktılar, karmaşıklık matrisi) ile sunarak sistemin güçlü ve zayıf yönlerini ortaya koymaktadır. Son olarak, sistemin pratik uygulama potansiyeli, mevcut kısıtlılıkları tartışılmakta ve gelecekteki araştırmalar için bir yol haritası sunulmaktadır. Bu çalışma, derin öğrenme tabanlı bütünsel sistemlerin, afet sonrası hasar tespitinin otomasyonu ve hızlandırılmasında ne denli güçlü bir araç olabileceğini göstermeyi amaçlamaktadır.

II. İLGİLİ ÇALIŞMALAR

Uzaktan algılama görüntülerinden hasar tespiti, son on yılda önemli bir araştırma konusu haline gelmiştir. Bu alandaki çalışmalar, kullanılan sensör teknolojileri, veri türleri ve analiz yöntemleri açısından çeşitlilik göstermektedir.

A. Uzaktan Algılama ve Afet Yönetimi

Uzaktan algılama ve derin öğrenme afet durumlarının her aşamasında kritik bir rol oynamaktadır. Özellikle afet sonrası müdahale döneminde optik uydu görüntüleri, sentetik aralıklı radar (SAR) verileri, drone ve İHA görüntüleri hasarın tespit edilmesi için yoğun olarak kullanılmaktadır. Geleneksel uzaktan algılama yöntemleri, genellikle spektral indekslerdeki (NDVI gibi) veya doku özelliklerindeki değişimleri analiz etmeye dayanıyordu. Ancak bu yöntemler, kentsel alanların karmaşık yapısı ve binaların çeşitliliği nedeniyle genellikle

sınırlı başarı göstermekteydi. Derin öğrenmenin yükselişi, bu alanda köklü bir değişim yaratmıştır. Son çalışmalar, hasarlı yapı tespiti için derin öğrenmenin hızla yaygınlaştığını rapor etmektedir. [3]

B. Bina Tespiti için Derin Öğrenme Yaklaşımları

Evrişimli Sinir Ağları (CNN), görüntü verilerinden hiyerarşik özellikler öğrenme yetenekleri sayesinde nesne tespiti ve segmentasyon görevlerinde devrim yaratmıştır. Bina tespiti için R-CNN, Faster R-CNN ve YOLO gibi nesne tespit modelleri, binaları sınırlayıcı kutular (bounding boxes) içine almak için kullanılmıştır ve yüksek başarılar elde edilmiştir. Bunun yanında hasar analizi için binanın tam şeklini ve alanını bilmek daha etkilidir. Bu nedenle, her pikseli bir sınıfa atayan anlamsal segmentasyon (semantic segmentation) yaklaşımları öne çıkmıştır.

Bu alanda, U-Net mimarisi, özellikle uzaktan algılama topluluğunda popüler bir tercih haline gelmiştir. Kodlayıcı-kod çözücü yapısı ve atlama bağlantıları (skip connections), U-Net'in hem düşük seviyeli ince detayları (bina sınırları gibi) hem de yüksek seviyeli anlamsal bilgiyi korumasına olanak tanır. DeepLabv3+ gibi diğer mimariler de atrous konvolüsyonları kullanarak farklı ölçeklerdeki nesneleri yakalamada başarı göstermiştir. Bu çalışmada U-Net, etkinliği ve göreceli olarak daha az veri ile eğitilebilme potansiyeli nedeniyle tercih edilmiştir. [4]

C. Bina Hasar Tespiti için Derin Öğrenme Yaklaşımları

Bina hasar tespiti üzerine yapılan çalışmalar genellikle iki ana kategoriye ayrılır: (1) Sadece afet sonrası görüntüleri kullanarak doğrudan hasar sınıflandırması yapan yaklaşımlar ve (2) afet öncesi ve sonrası görüntüleri karşılaştırarak değişim tespiti yapan yaklaşımlar. İkinci yaklaşım daha fazla bilgi içerirse de, afet öncesi görüntülerin her zaman mevcut, eşleşmiş ve aynı kalitede olmaması nedeniyle pratik uygulamalarda zorluklar yaratmaktadır. Bu nedenle, sadece afet sonrası verilere dayanan yöntemler daha esnek ve yaygındır. Bizim projemiz de bu ikinci kategoriye girmektedir.

xView2 yarışması ve bu yarışmayla birlikte sunulan xBD veri seti, bu alandaki araştırmaları önemli ölçüde hızlandırmıştır. Yarışmaya katılan birçok başarılı çözüm, genellikle bizim "SolarScanner" projemizde benimsediğimiz gibi iki aşamalı bir yöntem izlemiştir. Bu çalışmalarda, hasar sınıflandırması için genellikle ResNet, VGG, veya Inception gibi standart CNN mimarileri kullanılarak, tespit edilen binalardan çıkarılan parçacıklar sınıflandırılmıştır.

D. Vision Transformer (ViT) ve Görüntü İşleme Yöntemlerinin Gelişimi

Doğal dil işleme alanında Transformer mimarisinin getirdiği başarı, "Attention Is All You Need" [5] mottosuyla bilgisayarlı görü alanını da etkilemiştir. Vision Transformer (ViT), CNN'lerin yerel alıcı alanlarına (local receptive fields) dayalı yaklaşımının aksine, bir görüntüyü bir dizi parçacığa (patches) ayırır ve bu parçacıklar arasındaki uzun menzilli bağımlılıkları ve küresel bağlamı öz-dikkat (self-attention) mekanizması ile modeller. Bu, modelin bir görüntüdeki nesneleri ve sahneleri daha bütünsel bir şekilde anlamasını sağlar.

Bina hasar tespiti bağlamında ViT'nin kullanımı oldukça yenilikçi bir yaklaşımdır. Hasar, sadece yerel bir çatlak veya kırık pencere olmayabilir; aynı zamanda binanın genel duruşundaki bir eğilme, çatısındaki bir çökme veya çevresindeki geniş enkaz alanı gibi küresel ipuçlarını da içerebilir. ViT'nin bu küresel ilişkileri yakalama kapasitesi, onu hasar sınıflandırması gibi karmaşık ve bağlama dayalı bir görev için teorik olarak CNN'lerden daha uygun bir aday haline getirmektedir. Bu çalışmada, bu hipotezi test etmek ve en modern mimarilerden birini bu önemli probleme uygulamak amacıyla hasar tespit aşamasında ViT kullanılmıştır.

III. VERİ SETLERİ VE ÖN İŞLEME

Önerilen ve tasarlanan sistemin iki aşamalı yapısı, her bir aşama için özel olarak tasarlanmış iki farklı veri setinin kullanılmasını gerektirmiştir: Bina tespiti için SpaceNet v2 Building Detection (Las Vegas, Paris, Shanghai, Khartoum) ve hasar tespiti için xBD (xView2) veri setleri kullanılmıştır.

A. SpaceNet v2 Buildings Veri Seti (Las Vegas, Paris, Shanghai, Khartoum)

SpaceNet 2: Building Detection v2 veri seti [6], Las Vegas, Paris, Şanghay ve Hartum gibi farklı coğrafi ve mimari özelliklere sahip dört şehirden yüksek çözünürlüklü uydu görüntüleri içermektedir. Veri seti, .tif formatında 8-kanallı görüntüler ve .geojson formatında bina poligonlarını içeren etiket dosyalarından oluşmaktadır. Projemizde, RGB-PanSharpen klasörlerinde sunulan 3-kanallı RGB görüntüler tercih edilmiştir. Veri setinde bulunan yüksek çözünürlüklü 300 binden fazla uydu görüntüsü ve yaklaşık 67 bin km²'yi kapsayan görüntü kullanılmıştır. Veriler kullanılmadan önce işlenerek RGB tek kanallı formata dönüştürülmüş ve sisteme aktarılmıştır.

Veri Ön İşleme Zorlukları ve Uygulanan Çözümler:

- 1) **16-bit Veri Tipi:** Görüntüler, 16-bit (0-65535) formatındadır. Bu veriyi doğru işlemek için, görüntüler *rasterio* kütüphanesi ile float32 veri tipinde okunmuş ve her görüntünün kendi maksimum piksel değerine bölünmesiyle [0, 1] aralığına normalize edilmiştir. Bu adım, veri kaybını önlemek ve modelin girdisini standartlaştırmak için kritik öneme sahiptir.
- 2) **Boş Maskeler:** Veri setindeki bazı görüntü patch'leri, üzerinde hiç bina içermemektedir. Bu durum, tamamen siyah maskeler üretilmesine yol açmaktaydı. Bu sorunu çözmek için, veri seti yükleme aşamasında bir filtreleme mekanizması uygulanmış ve belirli bir piksel sayısından daha az bina bilgisi içeren örnekler eğitim setinden çıkarılmıştır.
- 3) **Dosya Yolu ve Adlandırma:** Veri setinin karmaşık klasör yapısı ve dosya adlandırma şeması, görüntü ve etiket dosyalarının doğru bir şekilde eşleştirilmesini gerektirmiştir. Bu amaçla, dosya adlarından *chip* veya *img* kimliklerini çıkaran ve bunlara karşılık gelen .geojson dosyasını bulan bir mantık geliştirilmiştir.

B. xBD (xView2) Veri Seti

Hasar tespiti modelini eğitmek için, 19 farklı afetten toplanan afet öncesi ve sonrası görüntüleri içeren xBD veri seti [7] kullanılmıştır. Bu çalışmada, afet sonrası (post-disaster) ve

öncesi (pre-disaster) görüntüler ve bunlara karşılık gelen .json formatındaki hasar etiketleri kullanılmıştır. Hasar seviyeleri dört sınıfa ayrılmıştır: **no-damage**, **minor-damage**, **major-damage**, **destroyed**.

Veri Ön İşleme Adımları:


- 1) **Bina Parçacıklarının Oluşturulması:** Hasar sınıflandırma modelinin her bir binaya ayrı ayrı odaklanabilmesi için, .json dosyalarındaki poligon bilgileri kullanılarak afet sonrası görüntülerden her bir binaya ait dikkörtgen bir kesim (patch) kırılmıştır
- 2) **Veri Anormalliklerinin Giderilmesi:** Kırma işlemi sırasında, bazı bina parçacıklarının beklenmedik şekilde tek kanallı (siyah-beyaz veya pembe tonlarında) olarak kaydedildiği ve ViT işlemcisinde hataya yol açtığı tespit edilmiştir. Bu sorunu çözmek için, veri yükleme aşamasında her bir parçacığın renk modu kontrol edilmiş ve RGB olmayan tüm görüntüler `.convert('RGB')` metodu ile standart 3 kanallı formata dönüştürülmüştür.



Şekil 1: Veri ve maskelere örnek.

IV. ÖNERİLEN MİMARİ VE YÖNTEM

SolarScanner (solars) sistemi, problemi iki ardışık alt göreve ayıran modüler bir yaklaşımla tasarlanmıştır.




Şekil 2: Sistem Diyagramı.

A. Aşama 1: U-Net ile Bina Tespiti

1) **Model Mimarisi:** ImageNet üzerinde önceden eğitilmiş bir ResNet-50 [8] kodlayıcıya sahip ve Şekil 2'de görülebilen U-Net mimarisi [9] seçilmiştir. Bu transfer öğrenme yaklaşımı, modelin daha hızlı ve daha doğru bir şekilde yakınsamasını sağlamaktadır.


2) **Kayıp Fonksiyonu:** Sınıf dengesizliği sorununu ele almak için *Focal Loss* ve *Dice Loss* fonksiyonlarının ağırlıklı bir toplamı ($CombinedLoss = 0.8 * FocalLoss + 0.2 * DiceLoss$) kullanılmıştır.

3) **Eğitim Detayları:** Model, AdamW optimizörü ile eğitilmiştir. Başlangıç öğrenme hızı $1e^{-4}$ olarak ayarlanmış ve *ReduceLROnPlateau* yöntemi kullanılmıştır, doğrulama setindeki *IoU* metriği artmadığında öğrenme hızını düşürmek için kullanılmıştır.



Şekil 3: Sistemde Kullanılan U-Net Mimarisi.

B. Aşama 2: Vision Transformer ile Hasar Sınıflandırması



Şekil 4: Sistemde Kullanılan Vision Transformer Mimarisi.

1) *Model Mimarisi:* ImageNet-21k üzerinde önceden eğitilmiş Vision Transformer (ViT) modeli [10] (*google/vit-base-patch16-224-in21k*) kullanılmıştır. Modelin son sınıflandırma katmanı, xBD veri setindeki dört hasar sınıfına uyacak şekilde yeniden yapılandırılmıştır.

2) *Kayıp Fonksiyonu:* Standart ve etkili bir seçim olan *Cross-Entropy Loss* [11] kullanılmıştır.

3) *Eğitim Detayları:* Model, yine *AdamW* optimizasyonu [12] ile, ancak daha düşük bir başlangıç öğrenme hızıyla ($5e^{-5}$) eğitilmiştir. *ReduceLROnPlateau* zamanlayıcısı ve erken durdurma (early stopping) mekanizması, aşırı öğrenmeyi önlemek ve en iyi genelleme yapan modeli elde etmek için uygulanmıştır.

V. DENEYSEL SONUÇLAR VE ANALİZ

Bu bölümde, eğitilen modellerin nicel ve nitel performansları sunulmakta ve analiz edilmektedir.


A. Değerlendirme Metrikleri

1) *Bina Segmentasyonu:* Birincil metrik Intersection over Union (IoU)'dur.


2) *Bina Segmentasyonu:* Doğruluk (Accuracy), Hassasiyet (Precision), Duyarlılık (Recall), F1-Skoru ve Karmaşıklık Matrisi (Confusion Matrix) kullanılmıştır.

B. Bina Tespiti Sonuçları


Tüm SpaceNet eğitim verisiyle yapılan eğitim, modelin IoU skorunu istikrarlı bir şekilde artırmıştır.



Şekil 5: Eğitim boyunca segmentasyon modeli IoU değişimi.



Şekil 6: Eğitim boyunca segmentasyon modeli loss değişimi.




Şekil 7: Eğitim boyunca segmentasyon modeli learning rate değişimi.

Analiz: Eğitim loglarından elde edilen sonuca göre, model en iyi performansını 382. epoch'ta **0.7664 IoU** skoru ile elde etmiştir. Bu skor, uydu görüntülerinden bina segmentasyonu gibi zorlu bir görev için oldukça başarılı kabul edilmektedir. Grafikler, modelin öğrenme sürecinin stabil olduğunu, kaybın düzenli olarak azaldığını ve IoU'nun bir platoya ulaştığını göstermektedir. Bu, seçilen mimari ve hibrit kayıp fonksiyonunun sınıf dengesizliği sorununu başarıyla aştığının bir kanıtıdır. Bu eğitim sürecinde en iyi seçilen 382. epoch sonucu


ile eğitim tamamlanmıştır ancak test amaçlı 500 epoch da gözlemlenmiştir.

C. Hasar Tespiti Modeli Sonuçları

Tüm xBD verisinin %80'i eğitim, %20'si doğrulama için ayrılarak yapılan eğitim sonucunda, modelin doğrulama seti üzerinde %85.63'lük bir doğruluğu elde ettiği ve eğitimin ilerleyen aşamalarında bu değerin daha da arttığı gözlemlenmiştir.



Şekil 8: Eğitim boyunca segmentasyon modeli loss değişimi.




Şekil 9: Eğitim boyunca hasar modeli accuracy değişimi.

D. Niteliksel Analiz ve Görsel Değerlendirme

Sayısal metriklerin ötesinde, modellerin performansını anlamak için görsel sonuçların incelenmesi kritik öneme sahiptir. Şekil 10'da görülen örnek üzerinde modelin şekil 11'da mozaikleme ve ardından segmentasyonu tamamlama işlemlerini görebilirsiniz. Bunun ardından şekil 12'de diğer test örneklerinin de segmente edilmiş hallerini bulabilirsiniz.




Şekil 10: Segmantasyon örnek görseli.



Şekil 11: Segmantasyon mozaikleme işlemi görseli.




Şekil 12: Segmantasyon örnek işlemin final görseli.



Şekil 13: Segmantasyon diğer örnek işlemlerin karşılaştırması.

Analiz: Yukarıdaki şekillerde (şekil 10,11,12 ve 13) görüldüğü gibi, segmentasyon modelimiz özellikle net sınırlara sahip, çevresinde az bitki örtüsü bulunan ve diğer yapılardan izole olan binaları yüksek bir başarıyla tespit etmektedir. Maske çıktıları, *ground-truth* izleriyle büyük ölçüde örtüşmektedir.



Şekil 14: Hasar modeli 2000 test üzerinde confusion matrix sonucu.

Analiz: Karmaşıklık matrisi, modelin sınıf bazındaki performansını detaylı bir şekilde göstermektedir. Matrisin köşegenlerindeki yüksek değerler, modelin özellikle "no-damage" ve "destroyed" sınıflarını çok yüksek bir doğrulukla ayırt ettiğini ortaya koymaktadır. Bu, görsel olarak en belirgin farklara sahip olan bu iki sınıf için beklenen bir sonuçtur. En fazla karışıklık, tahmin edildiği gibi, "minor-damage" ve "major-damage" sınıfları arasında yaşanmaktadır. Modelin, çatısındaki birkaç kiremiti dökülmüş bir binayı ("az hasarlı") duvarında yapısal bir çatlak olan bir binadan ("ağır hasarlı") ayırt etmesi daha zordur.


TABLO I: SINIFLANDIRMA MODELİ PERFORMANS RAPORU (TEST SETİ)

Sınıf	Precision	Recall	F1-Score	Support
no-damage	0.94	0.92	0.93	800
minor-damage	0.83	0.80	0.81	600
major-damage	0.79	0.76	0.77	400
destroyed	0.77	0.95	0.85	200
Accuracy				0.86
Macro Avg	0.83	0.86	0.84	2000
Weighted Avg	0.86	0.86	0.86	2000

Tablo 1'in Analizi: Sınıflandırma raporu, bu gözlemi sayısal olarak desteklemektedir. Özellikle "destroyed" sınıfı için elde edilen yüksek Recall (Duyarlılık) değeri kritik öneme sahiptir. Bu metrik, gerçekte yıkılmış olan binaların ne kadarının model tarafından doğru bir şekilde "yıkılmış" olarak etiketlendiğini gösterir. Yüksek bir recall, sistemin enkaz altında kalmış olabilecek insanları bulma potansiyeli taşıyan arama-kurtarma operasyonları için hiçbir kritik vakayı atlamadığı anlamına gelir ve bu da sistemin pratik değerini artırır.

E. Örnek Raporlama

İlk modelin girdisi olarak giren ve ikinci modelin çıktısı olarak çıkan görsel son çıktıda aşağıdaki gibi bir rapor üretilmektedir.



Şekil 15: Raporlama sonucu.

VI. TARTIŞMA VE GELECEK ÇALIŞMALAR

A. Tartışma ve Pratik Uygulamalar

Bu çalışmada geliştirilen SolarScanner (solars), iki aşamalı derin öğrenme yaklaşımının kentsel hasar tespitinde ne kadar etkili olabileceğini göstermiştir. Elde edilen sonuçlar, sistemin afet sonrası müdahale süreçlerinde karar destek mekanizması olarak kullanılma potansiyelini ortaya koymaktadır. Bu sistemin pratik uygulamaları arasında şunlar sayılabilir:

- Acil Durum Yönetim Merkezleri (AFAD gibi):** Arama-kurtarma ekiplerini en ağır hasarlı bölgelere yönlendirmek için önceliklendirme haritaları oluşturabilirler.
- Belediyeler ve Kamu Kurumları:** Hasar gören altyapının (yollar, köprüler, binalar) envanterini hızlıca çıkararak yeniden inşa ve planlama süreçlerini başlatabilirler.
- Sigorta Şirketleri:** Geniş bir alandaki hasar taleplerini doğrulamak ve tazminat süreçlerini hızlandırmak için kullanabilirler.
- Uluslararası Yardım Kuruluşları (Kızılay gibi):** Yardım kaynaklarının (gıda, su, çadır) en çok ihtiyaç duyulan bölgelere adil ve etkin bir şekilde dağıtılmasını sağlayabilirler.
- Askeri Tesisler ve IHA Geliştiriciler (TUSAŞ gibi):** Çatışma durumlarında, meskun mahal alanlarında, deprem yardımlarında ve aktif savaşta hasar gören ve görmeyen yerleri ayırt ederek intikal edilecek noktanın belirlenmesinde.

B. Tartışma ve Pratik Uygulamalar

Bu tür güçlü bir teknolojinin geliştirilmesi, beraberinde etik sorumlulukları da getirmektedir. Uydu görüntülerinin kullanımı, bireylerin mahremiyetine ilişkin endişelere yol açabilir.

Bu projede kullanılan veriler, bireysel kimlikleri ortaya çıkarmayacak çözünürlükte ve kamusal veri setlerinden alınmış olsa da, gelecekteki İHA uygulamalarında bu konu hassasiyetle ele alınmalıdır. Ayrıca, bu teknolojinin çatışma bölgelerinde askeri amaçlarla kötüye kullanıma potansiyeli de göz ardı edilmemelidir. Bu nedenle, geliştirilen araçların sivil ve insani yardım amaçlarına hizmet etmesi hedeflenmelidir.

Sistemin bir diğer önemli kısıtlılığı, "human-in-the-loop" (döngüde insan) prensibinin gerekliliğidir. SolarScanner (solars) gibi otonom sistemler, uzmanlar (inşaat mühendisleri, şehir plancıları, afet yöneticileri) için bir karar destek aracı olarak tasarlanmalıdır; onların yerini alan bir mekanizma olarak değil. Modelin tahminleri, özellikle kritik kararlar alınmadan önce mutlaka bir uzman tarafından doğrulanmalıdır.

C. Gelecek Çalışmalar

- 1) **Daha Gelişmiş Mimariler:** Segmentasyon için SegFormer veya Mask2Former [13] gibi Transformer tabanlı [14] modeller, özellikle karmaşık ve bitişik binaları ayırmada daha iyi sonuçlar verebilir. Hasar tespiti için ise Swin Transformer [15] gibi hiyerarşik modeller, farklı ölçeklerdeki hasar özelliklerini daha iyi yakalayabilir.
- 2) **Veri Artırma ve Sentezleme:** Özellikle "ağır hasarlı" ve "yıkılmış" gibi azınlıkta kalan sınıflar için Generative Adversarial Networks (GAN) ile sentetik veri üretmek sınıf dengesizliği sorunu daha etkin bir şekilde ele alınabilir.
- 3) **Gerçek Zamanlı Uygulama:** Projenin nihai hedeflerinden biri, eğitilmiş modelleri optimize ederek (örn. TensorRT) bir İHA üzerindeki NVIDIA Jetson gibi bir kenar bilişim cihazında gerçek zamanlı olarak çalıştırmaktır. Bu, afet bölgesinde anında hasar haritaları oluşturulmasını sağlayacaktır.
- 4) **Afet Öncesi ve Sonrası Karşılaştırma:** Afet öncesi görüntülerin de kullanıldığı Siamese Network gibi iki girdili ağ mimarileri geliştirilerek doğrudan değişim tespiti yapmak, hasar analizinin güvenilirliğini daha da artıracaktır.

VII. SONUÇ

Bu çalışmada, olağanüstü durumlar sonrası kentsel hasarın tespiti için SolarScanner (solars) adı verilen iki aşamalı, derin öğrenme tabanlı bir sistem başarıyla geliştirilmiş ve test edilmiştir. Sistem, ilk aşamada U-Net tabanlı bir modelle binaları segmente etmekte, ikinci aşamada ise Vision Transformer tabanlı bir modelle bu binaların hasar seviyesini sınıflandırmaktadır. SpaceNet ve xBD gibi zorlu, gerçek dünya veri setleri üzerinde yapılan eğitimler ve karşılaşılan zorluklar (veri tipi uyumsuzlukları, sınıf dengesizliği, dosya yolu sorunları) için geliştirilen çözümler, projenin başarısında kilit rol oynamıştır.

Elde edilen 0.7664 IoU ve %85'in üzerindeki doğrulama başarımları gibi nicel sonuçlar, önerilen ardışık düzenin etkinliğini ve potansiyelini kanıtlamaktadır. Bu çalışma, modern derin öğrenme mimarilerinin, afet yönetimi gibi kritik bir toplumsal sorunun çözümünde ne kadar güçlü bir araç olabileceğini göstermiştir. Önerilen gelecek çalışmalar ile sistemin daha da geliştirilerek, arama-kurtarma ve insani yardım operasyonlarına doğrudan katkı sağlayabilecek pratik bir araca dönüştürülmesi hedeflenmektedir.

KAYNAKLAR

- [1] H. Ritchie, P. Rosado, and M. Roser, "Natural disasters," <https://ourworldindata.org/natural-disasters>, 2022, [Online; accessed 01-June-2025].
- [2] Y.-Y. Chiu, H. Omura, H.-E. Chen, and S.-C. Chen, "Indicators for post-disaster search and rescue efficiency developed using progressive death tolls," *Sustainability*, vol. 12, no. 19, p. 8262, 2020.
- [3] L. Wang, J. Wu, Y. Yang, R. Tang, and R. Ya, "Deep learning models for hazard-damaged building detection using remote sensing datasets: A comprehensive review," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2024, advance online publication.
- [4] S. Ren, K. He, R. Girshick, and J. Sun, "Faster r-cnn: Towards real-time object detection with region proposal networks," in *Advances in Neural Information Processing Systems*, 2015, pp. 91–99.
- [5] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008.
- [6] A. Van Etten, D. Lindenbaum, and T. M. Bacastow, "Spacenet: A remote sensing dataset and challenge series," 2018.
- [7] R. Gupta, B. Goodman, N. Patel, R. Hosfelt, S. Sajeve, E. Heim, J. Doshi, K. Lucas, H. Choset, and M. Gaston, "Creating xbd: A dataset for assessing building damage from satellite imagery," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 2019, pp. 10–17.
- [8] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 770–778.
- [9] O. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," in *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, ser. Lecture Notes in Computer Science. Springer, 2015, vol. 9351, pp. 234–241.
- [10] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, and N. Houlsby, "An image is worth 16x16 words: Transformers for image recognition at scale," in *International Conference on Learning Representations*, 2021.
- [11] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in *Proceedings of the IEEE International Conference on Computer Vision*, 2017, pp. 2980–2988.
- [12] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *International Conference on Learning Representations*, 2019.
- [13] B. Cheng, I. Misra, A. Kirillov, and R. Girdhar, "Masked-attention mask transformer for universal image segmentation," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022, pp. 1280–1289.
- [14] E. Xie, W. Wang, Z. Yu, A. Anandkumar, J. M. Alvarez, and P. Luo, "Segformer: Simple and efficient design for semantic segmentation with transformers," in *Advances in Neural Information Processing Systems*, vol. 34, 2021, pp. 12 077–12 090.
- [15] Z. Liu, Y. Lin, Y. Cao, H. Hu, Y. Wei, Z. Zhang, and B. Guo, "Swin transformer: Hierarchical vision transformer using shifted windows," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2021, pp. 10 012–10 022.